

Extraction d'information Cours 4

Nassim ZELLAL

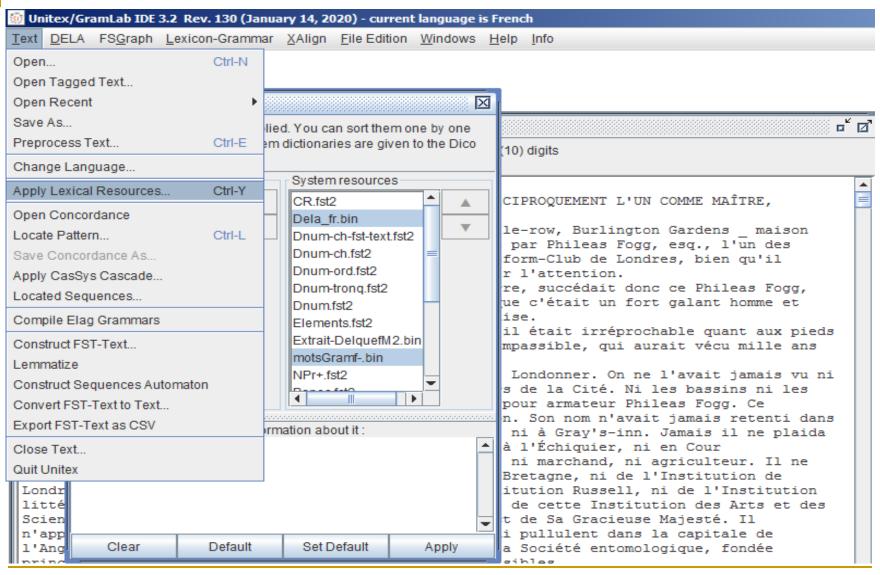
Les dictionnaires DELA

- DELAF:utilisés pour extraire de l'information et annoter des mots. Ils peuvent être exploités par des graphes (grammaires) d'extraction.
- DELAS:utilisés pour faire de la flexion automatique en appelant des graphes flexionnels.

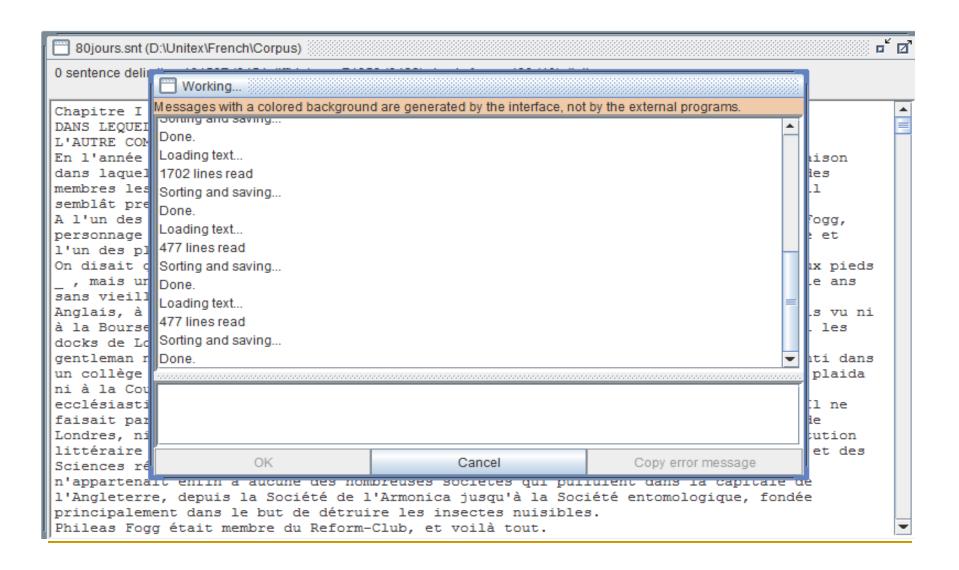
Format du DELAF

- lieutenants, lieutenant. N+z1:mp
- Forme fléchie, lemme (ou forme canonique), information grammaticale+information sémantique: informations morphologiques (informations flexionnelles)

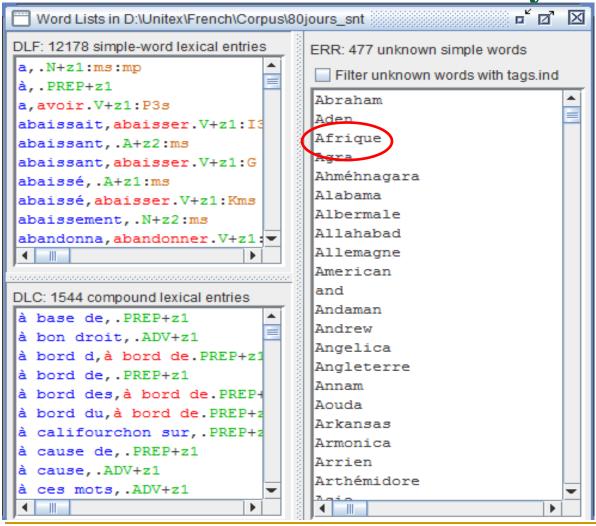
Application des dictionnaires du système



Application des dictionnaires du système



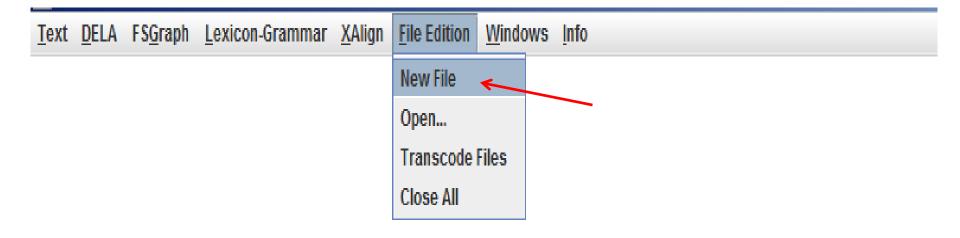
Résultat sur UNITEX après l'application des dictionnaires du système



Afrique est un mot simple inconnu du dictionnaire

« Dela fr.bin »

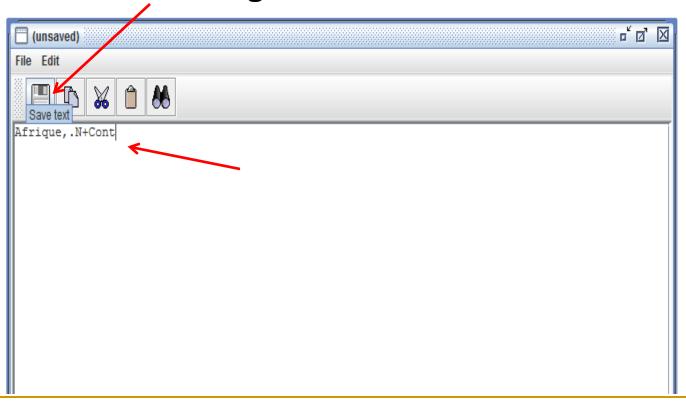
Création d'un dictionnaire DELAF



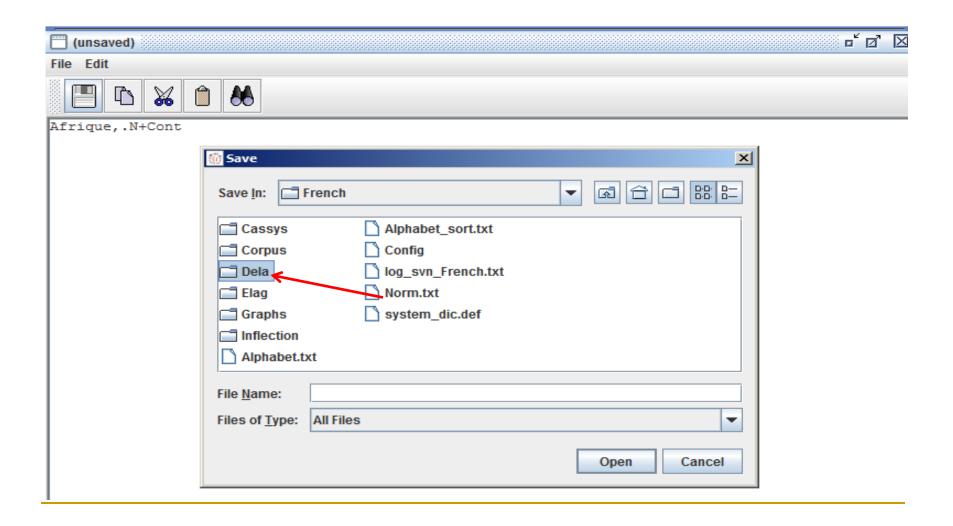
Saisir l'entrée lexicale avec les informations grammaticales et sémantiques

<u>Text DELA FSGraph Lexicon-Grammar XAlign File Edition Windows Info</u>

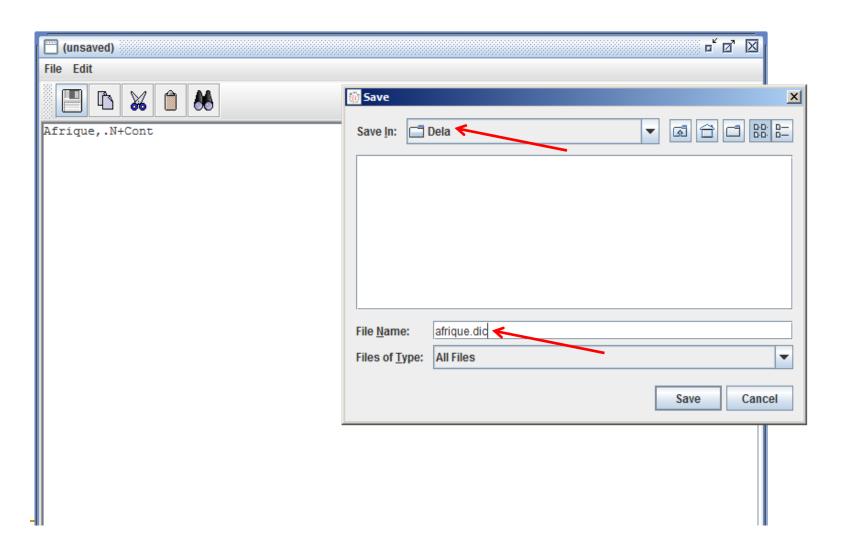
Enregistrer le fichier édité en .dic



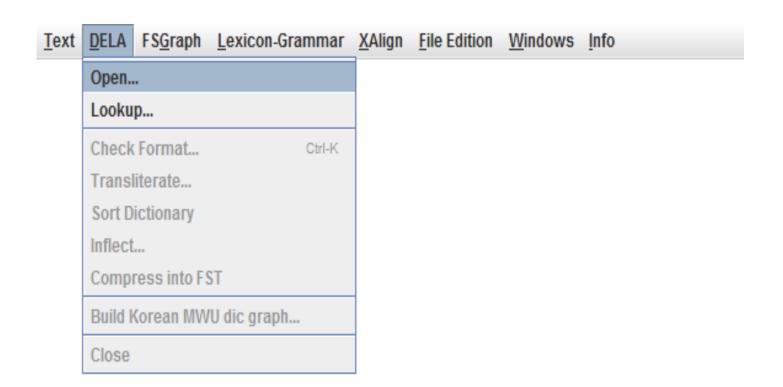
Enregistrer le dictionnaire dans le répertoire Dela en « .dic »



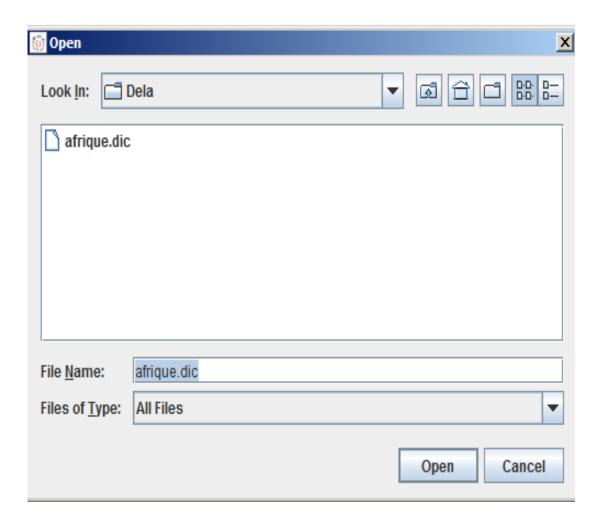
Enregistrer le dictionnaire dans le répertoire Dela en « .dic »



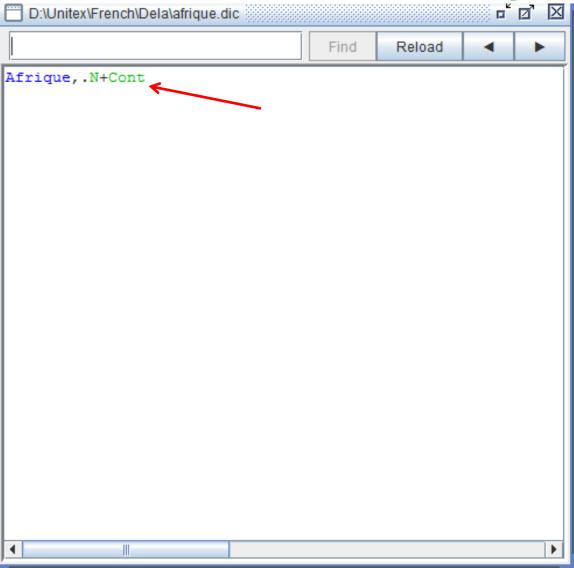
Ouvrir le dictionnaire enregistré



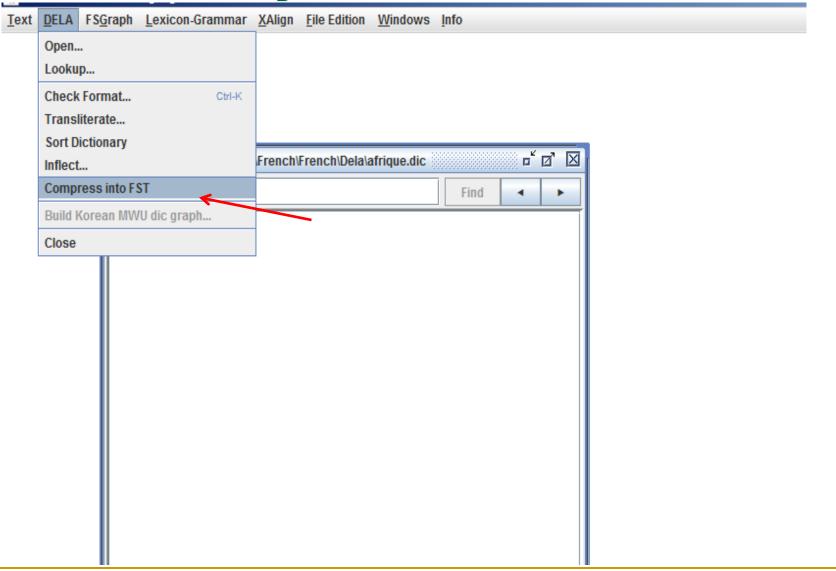
Ouvrir le dictionnaire enregistré



Ouvrir le dictionnaire enregistré



Compression d'un DELAF



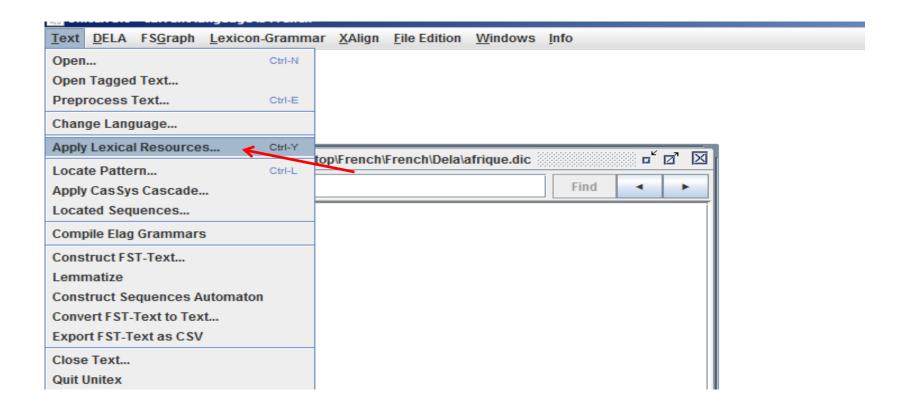
Compression du DELAF effectuée

Done Done		
Messages with a colored background are generated	by the interface, not by the external programs.	
Compressing C:\Users\user\Desktop\French\French\Dela\afrique.dic		
Minimizing		
Minimization done.		
Binary file: 32 bytes		
1 line read		
1 INF entry created		
8 states, 7 transitions		
ОК	Cancel	
	-	

Résultat de la compression du DELAF au format FST

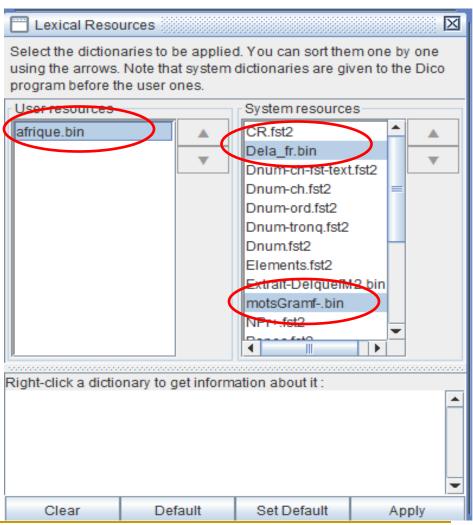


Application du DELAF sur le texte

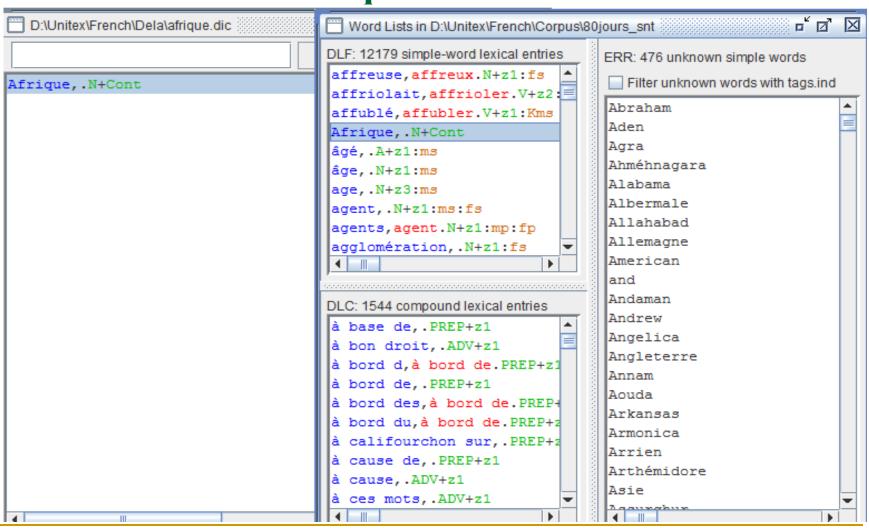


Application des ressources de l'utilisateur et des ressources du système sur le texte

La ressource (dictionnaire DELAF) de l'utilisateur « <u>afrique.bin</u> » sera appliquée sur le texte ainsi que les deux ressources par défaut du système.



Le mot « Afrique » fait partie à présent des mots simples connus



Recherche d'expressions régulières

- Masques lexicaux.
- Négation d'un masque lexical.
- La concaténation.
- L'union.
- Étoile de Kleene.
- Filtres morphologiques.

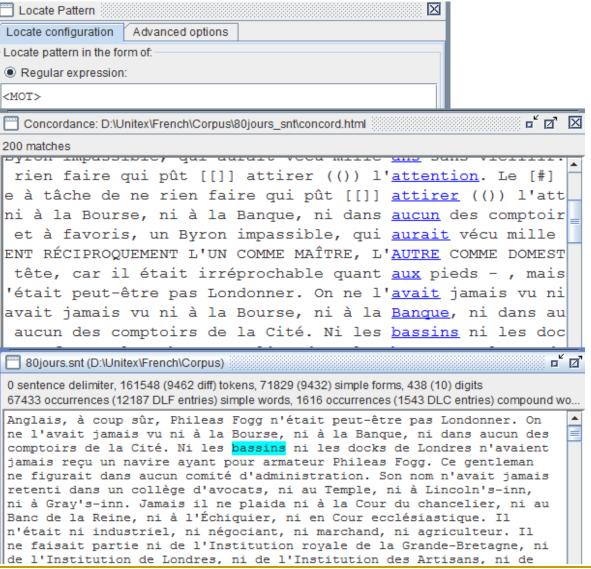
Masques lexicaux

- Un masque lexical est une requête, qui reconnaît une unité lexicale ou une suite d'unités lexicales.
- Masques lexicaux simples :
 - symboles spéciaux (ou méta-symboles);
 - référence aux informations fournies par les dictionnaires.
- Masques lexicaux complexes :
 - contraintes grammaticales;
 - contraintes sémantiques;
 - contraintes flexionnelles.

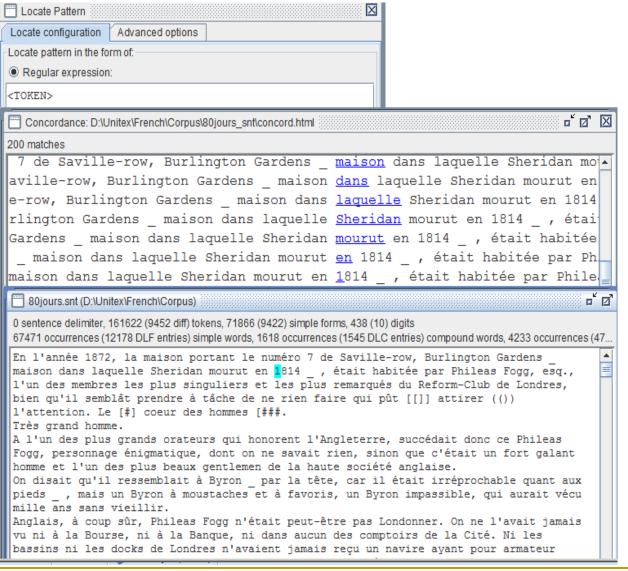
Masques lexicaux simples - symboles spéciaux

- <MOT>,<WORD>: reconnaît n'importe quelle suite de lettres.
- <MIN>,<LOWER>: reconnaît n'importe quelle suite de lettres minuscules.
- <MAJ>,<UPPER>: reconnaît n'importe quelle suite de lettres majuscules.
- <PRE>,<FIRST>: reconnaît n'importe quelle suite de lettres commençant par une majuscule.
- <PNC> : reconnaît les symboles/signes de ponctuation. Ce symbole n'est valide que pendant la phase de « prétraitement ».
- **<TOKEN>:** reconnaît n'importe quelle unité lexicale sauf l'espace.
- **<DIC>:** reconnaît n'importe quel mot figurant dans les dictionnaires du texte.
- **<SDIC>:** reconnaît n'importe quel mot simple figurant dans les dictionnaires du texte.
- <CDIC>: reconnaît n'importe quel mot composé figurant dans les dictionnaires du texte.
- <NB>: reconnaît n'importe quelle suite de chiffres contigus.

Masques lexicaux simples - symboles spéciaux



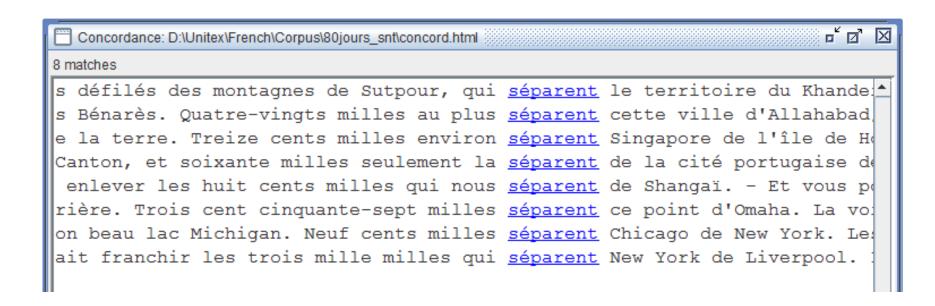
Masques lexicaux simples - symboles spéciaux



Masques lexicaux simples - référence aux informations fournies par les dictionnaires

- <avoir>: reconnaît toutes les entrées qui ont « avoir » comme forme canonique (lemme).
- <part>: reconnaît toutes les entrées qui ont « part » comme forme canonique.
- <séparent,séparer.V>: reconnaît toutes les entrées qui ont <u>séparent</u> comme forme fléchie, <u>séparer</u> comme forme canonique (ou lemme) et qui ont le code grammatical <u>V</u> (VERBE).

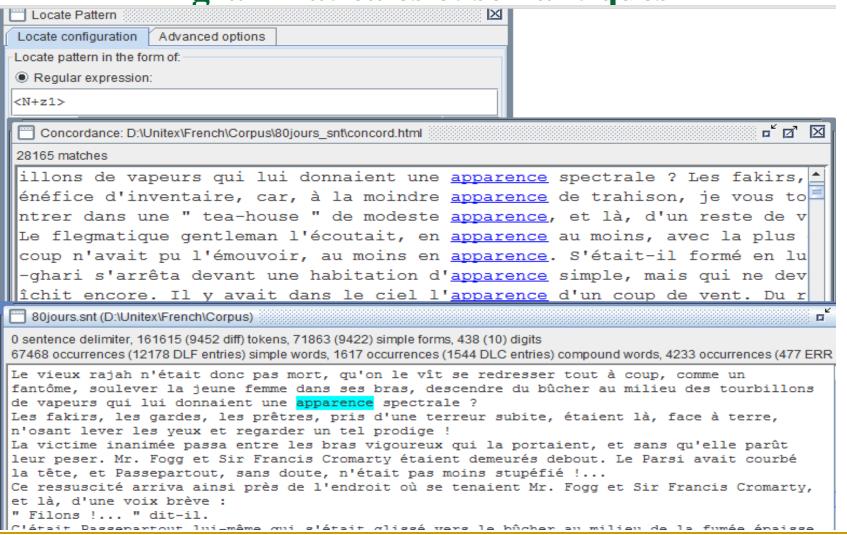
Masques lexicaux simples - référence aux informations fournies par les dictionnaires



Masques lexicaux complexes - contraintes grammaticales et sémantiques

- <N+z1>: reconnaît dans le texte
- apparences,apparence.N+z1:fp
- rues,rue.N+z1:fp
- tables,table.N+z1:fp
- ______
- <A+z1> : reconnaît dans le texte
- fantastiques,fantastique.A+z1:mp:fp

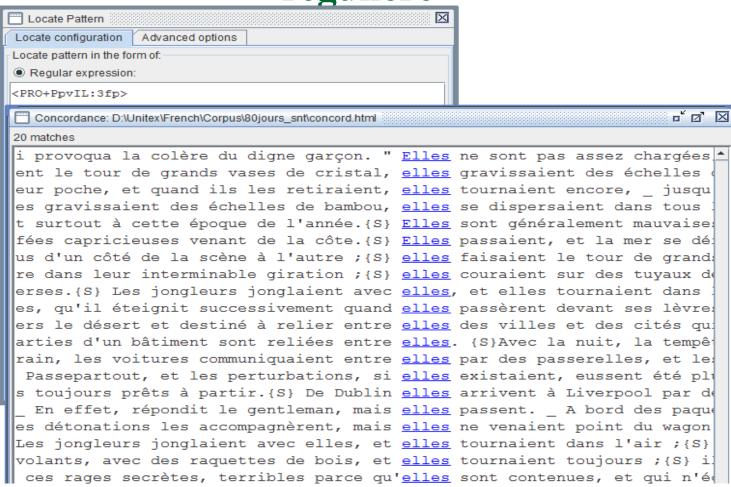
Masques lexicaux complexes - contraintes grammaticales et sémantiques



Masques lexicaux complexes - contraintes flexionnelles

- <A:m>: reconnaît un adjectif au masculin.
- <A:mp:f>: reconnaît un adjectif au masculin pluriel ou au féminin.
- <V:2:3> : reconnaît un verbe à la deuxième ou troisième personne.
- Voyons l'exemple du masque lexical :
- <PRO+PpvIL:3fp> → <CAT+sous-CAT:flexion>

Résultat de l'application du masque lexical <PRO+PpvIL:3fp> sous forme d'expression régulière



Négation d'un masque lexical

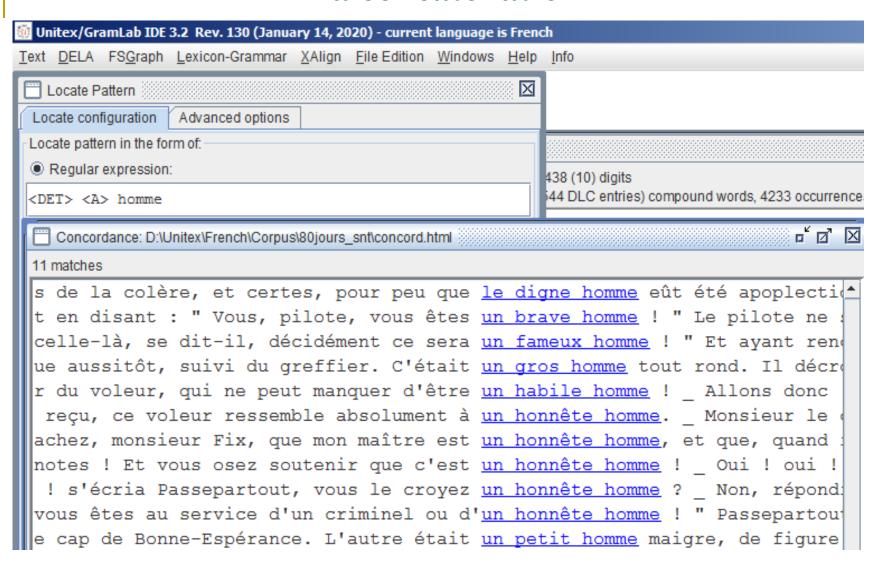
- <!MOT>/<!WORD> (reconnaît des unités lexicales qui ne se pas formées de lettres : ponctuation, nombre)
- <!PRE>
- <!DIC> (mots inconnus du texte : Abraham)
- <!MIN>
- <!MAJ>
- <!V:mp>
- La négation est sans effet sur :
- <SDIC>
- <CDIC>
- < < NB>
- <TOKEN>

 Il est possible de concaténer des expressions régulières, en utilisant l'opérateur de concaténation représenté par le point.

<DET>.<A>.homme

🔯 Unitex/GramLab IDE 3.2 Rev. 130 (January 14, 2020) - current language is French		
$\underline{\underline{T}} \texttt{ext} \underline{\underline{D}} \texttt{ELA} FS \underline{\underline{G}} \texttt{raph} \underline{\underline{L}} \texttt{exicon-Grammar} \underline{\underline{X}} \texttt{Align} \underline{\underline{F}} \texttt{ile} \; \underline{Edition} \underline{\underline{W}} \texttt{indows} \underline{\underline{H}} \texttt{elp}$	<u>I</u> nfo	
Locate Pattern 🗵		
Locate configuration Advanced options		
Locate pattern in the form of:		
Regular expression:	438 (10) digits	
<det>.<a>.homme</det>	44 DLC entries) compound words, 4233 occurrence	
Concordance: D:\Unitex\French\Corpus\80jours_snt\concord.html		
11 matches		
s de la colère, et certes, pour peu que <u>le digne homme</u> eût été apoplecti		
t en disant : " Vous, pilote, vous êtes <u>un brave homme</u> ! " Le pilote ne :		
celle-là, se dit-il, décidément ce sera <u>un fameux homme</u> ! " Et ayant ren		
ue aussitôt, suivi du greffier. C'était <u>un gros homme</u> tout rond. Il décr		
r du voleur, qui ne peut manquer d'être <u>un habile homme</u> ! _ Allons donc		
reçu, ce voleur ressemble absolument à <u>un honnête homme</u> Monsieur le 📢		
achez, monsieur Fix, que mon maître est <u>un honnête homme</u> , et que, quand :		
notes ! Et vous osez soutenir que c'est <u>un honnête homme</u> ! _ Oui ! oui !		
! s'écria Passepartout, vous le croyez <u>un honnête homme</u> ? _ Non, répond:		
vous êtes au service d'un criminel ou d' <u>un honnête homme</u> ! " Passepartou		
e cap de Bonne-Espérance. L'autre était <u>un petit homme</u> maigre, de figure		

- Ou bien en utilisant l' « espace » ou rien.
- <DET> <A> homme
- <DET><A>homme

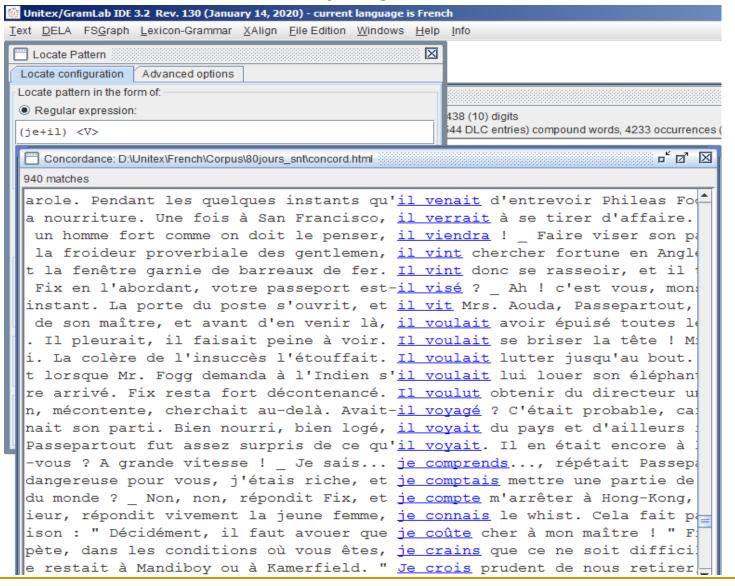


L'union

 L'union d'expressions régulières se fait en les séparant par le caractère +

(je+il) <V>

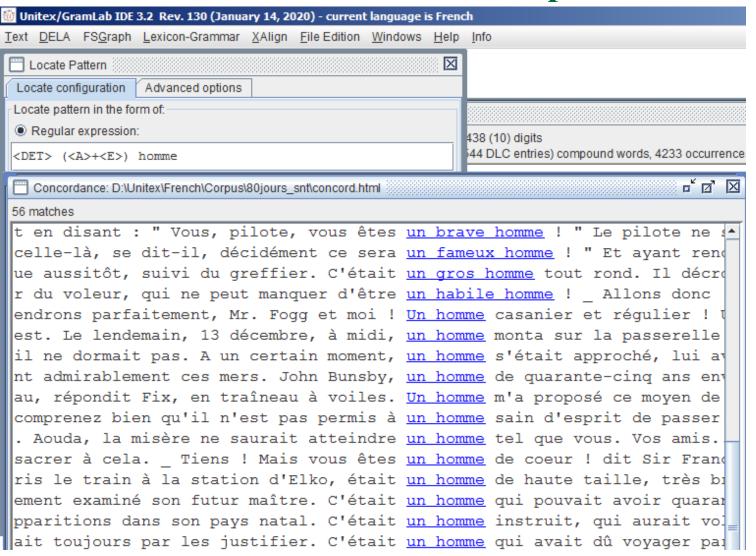
L'union



L'union avec le mode vide « epsilon »

- Si l'on souhaite rendre un élément de l'expression régulière facultatif, il suffit de faire l'union de cet élément avec le mode vide epsilon.
- <DET> (<A>+<E>) homme

L'union avec le mode vide « epsilon »



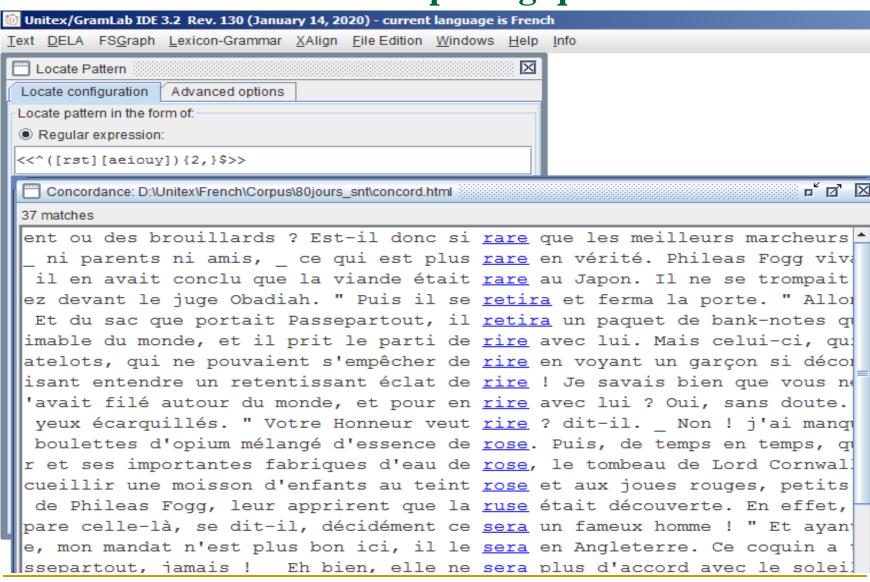
Étoile de Kleene

- L'étoile de Kleene est représentée par le caractère *.
 Ce dernier permet de reconnaître zéro ou plusieurs fois l'élément d'une expression régulière.
- Il fait très* froid → il fait froid, il fait très froid, il fait très très froid, etc.

Filtres morphologiques

- Sur Unitex, les filtres morphologiques peuvent être utilisés dans une expression régulière (Text>Locate Pattern>Regular expression) ou dans un graphe (Text>Locate Pattern>Graph).
- Le filtre <<^([rst][aeiouy]){2,}\$>> reconnaît :
- rare, rire, rose, sera, retira
- Le filtre <<^[aeiouy]{2,3}\$>> reconnaît :
- au, ai, eau, eue, oui
- Le filtre <<^u.?s\$>> reconnaît :
- uns, us
- Le filtre <<ss[^e]>> reconnaît :
- adressa, adressé, Mississippi, Missouri
- Le filtre <!DIC><<es\$>> reconnaît :
- James, Londres, Athènes

Filtres morphologiques



Exercice 1

- Appliquer l'expression régulière sur UNITEX <N> <A> sur le texte « 80jours.txt », en limitant la recherche à 10 matches.
- Analyser le résultat, en vérifiant le nombre d'unités lexicales reconnues dans ce texte.

Exercice 2

- À partir du texte « 80jours.txt » encodé en UTF-16-LE BOM.
- Extraire via un script Python toutes les entités nommées de type « Personne », qui sont exprimées sous la forme : Prénom Nom
- Écrire le résultat dans un fichier encodé en UTF-8 avec BOM.
- La sortie doit contenir :
- Résultat : Prénom Nom
- **...**